

# Segmentação de madeira utilizando visão computacional clássica e CNN

Felipe Alfredo Nack

Programa de Pós-Graduação em Engenharia de Automação e Sistemas

[felipe.a.nack@gmail.com](mailto:felipe.a.nack@gmail.com)

## Abstract

O objetivo deste trabalho é aplicar técnicas de visão computacional clássica e redes neurais convolucionais na segmentação de madeira em imagens. A segmentação por visão clássica é feita através de uma limiarização no espaço de cor HSV, seguida de operações morfológicas de fechamento, abertura e por fim é aplicado o algoritmo de envoltório convexo. A aplicação da CNN trata de uma segmentação semântica seguindo a estrutura da U-Net em conjunto com o modelo Resnet34. Ambas abordagens apresentaram bons resultados e, por fim, escolheu-se a segmentação semântica da CNN em conjunto com um pós processamento envolvendo os algoritmos clássicos de visão.

## 1. Introdução

O setor de painéis de madeira no Brasil apresenta grande relevância, produzindo em 2005 mais de 7.7 milhões de m<sup>3</sup>, valor bastante expressivo que representa um crescimento de 9.5% ao ano desde 1995. Nesse mesmo setor é comum classificar as lâminas utilizadas para a confecção dos painéis e, no geral, essa classificação depende muito das propriedades da tora de madeira laminada.

Um dos desafios dessa indústria é a extração dessas características de forma automática, permitindo que as toras de madeira possam ser classificadas de acordo com seu potencial de gerar boas lâminas. Um exemplo de tora de madeira que pode ter suas características extraídas está apresentado na Figura 1.



Figure 1: Tronco de madeira recém cortado.

Contudo, é comum que esse tipo de imagem apresente ruído, como os elementos do fundo da Figura 1, dificultando a análise da madeira. Nesse sentido o presente trabalho propõe resolver o problema dos ruídos presentes na imagem, através de técnicas aplicadas para executar a segmentação da tora de madeira. Essa segmentação permite que a Figura 1 seja processada de forma que o resultado final seja aquele apresentado na Figura 2.

A partir dessa imagem segmentada é possível extrair características com maior facilidade, como por exemplo a dimensão da face e a quantidade de anéis de crescimento presentes.



Figure 2: Madeira segmentada na imagem.

## 2. Metodologia

A primeira forma de resolver esse problema é através das técnicas disponíveis na visão computacional clássica. O

método aqui empregado faz inicialmente uma limiarização no espaço de cor HSV, buscando filtrar da melhor forma possível os pixels que possuem tons parecidos com o da madeira. É natural que esse tipo de abordagem deixe ruídos na imagem, que aqui são tratados através de operações morfológicas de fechamento e abertura, respectivamente. As operações de fechamento e abertura, quando realizadas em sequência com um kernel de mesmo tamanho, tem a propriedade de conservar o tamanho dos objetivos e eliminar ruídos que ligam objetos diferentes. Se as operações de fechamento e abertura forem realizadas com sucesso, a imagem resultante deve ser parecida com a da Figura 3.

Na sequência basta realizar a análise de componentes conexos, selecionar o maior elemento presente na imagem e, então, aplicar um algoritmo de geração de envoltório convexo para reconstruir o formato da madeira. Perceba que essa sequência de processamento funciona bem para toras de madeira cuja face tem formato próximo de uma elipse. O resultado deve ser parecido com aquele visto na Figura 4. Perceba que o elemento maior em tons de cinza é justamente a madeira segmentada.

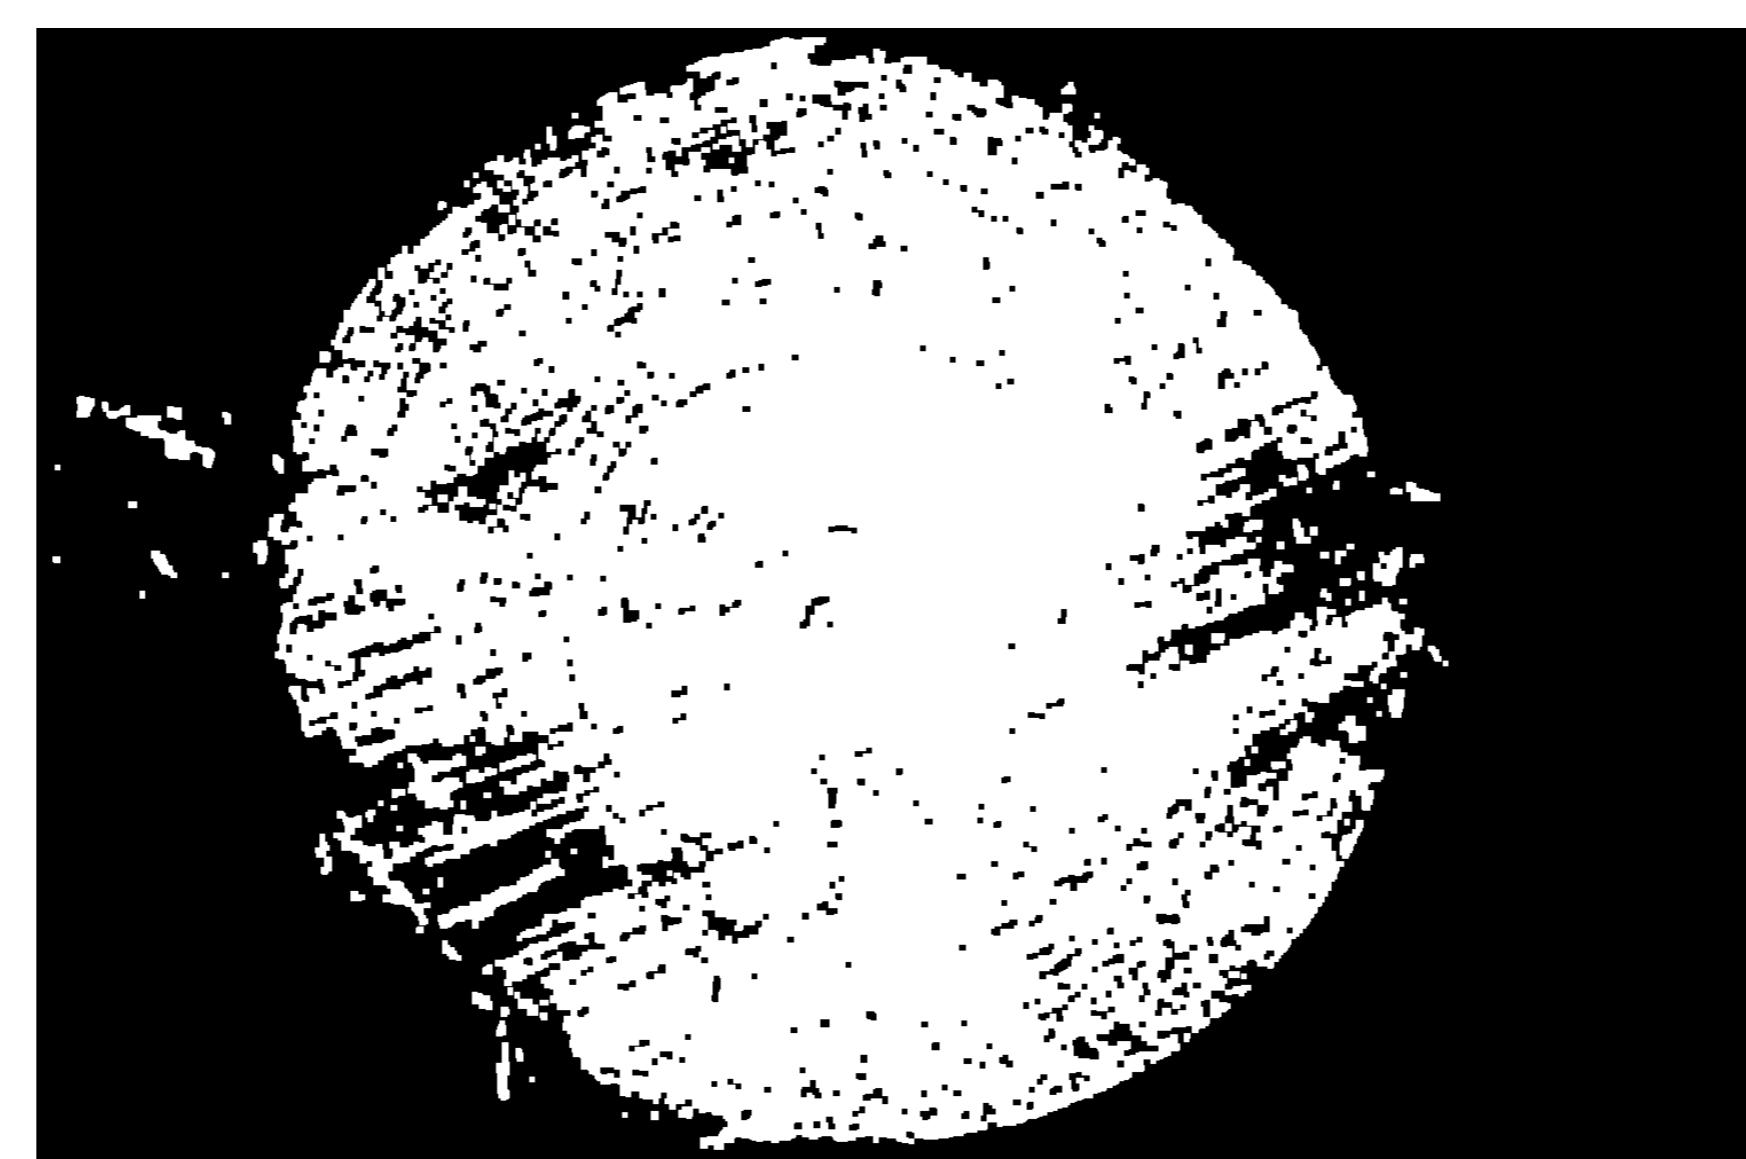


Figure 3: Operações morfológicas.

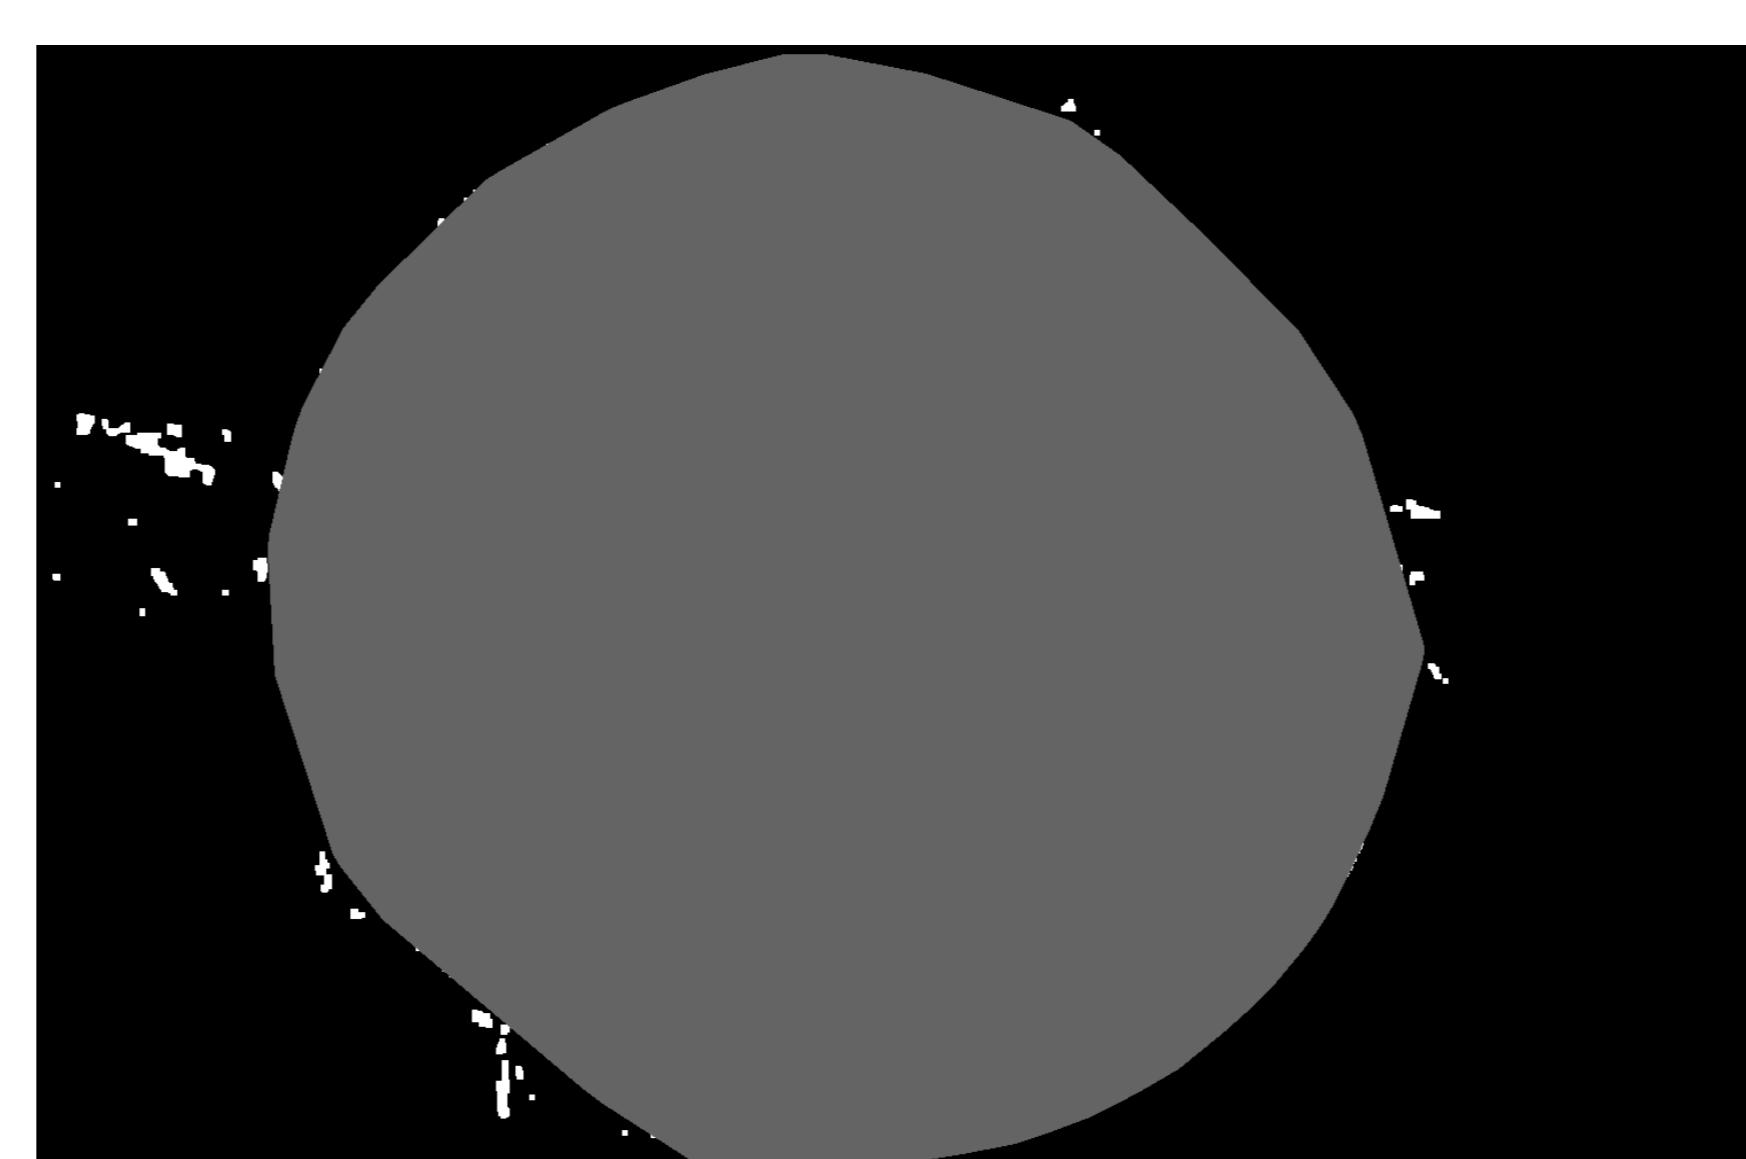


Figure 4: Algoritmo de envoltório convexo.

A segunda forma de resolver o problema da segmentação é através do uso de uma CNN. A arquitetura de CNN escolhida para esse trabalho é a da U-Net, utilizando-se do modelo Resnet34. O uso de ambos os elementos em conjunto permite realizar a segmentação de objetos em imagens. Conforme indica a Figura 5, a arquitetura da U-Net nada mais é do que um modelo de CNN (Resnet34 nesse caso) ligado ao seu equivalente invertido, permitindo realizar a segmentação.

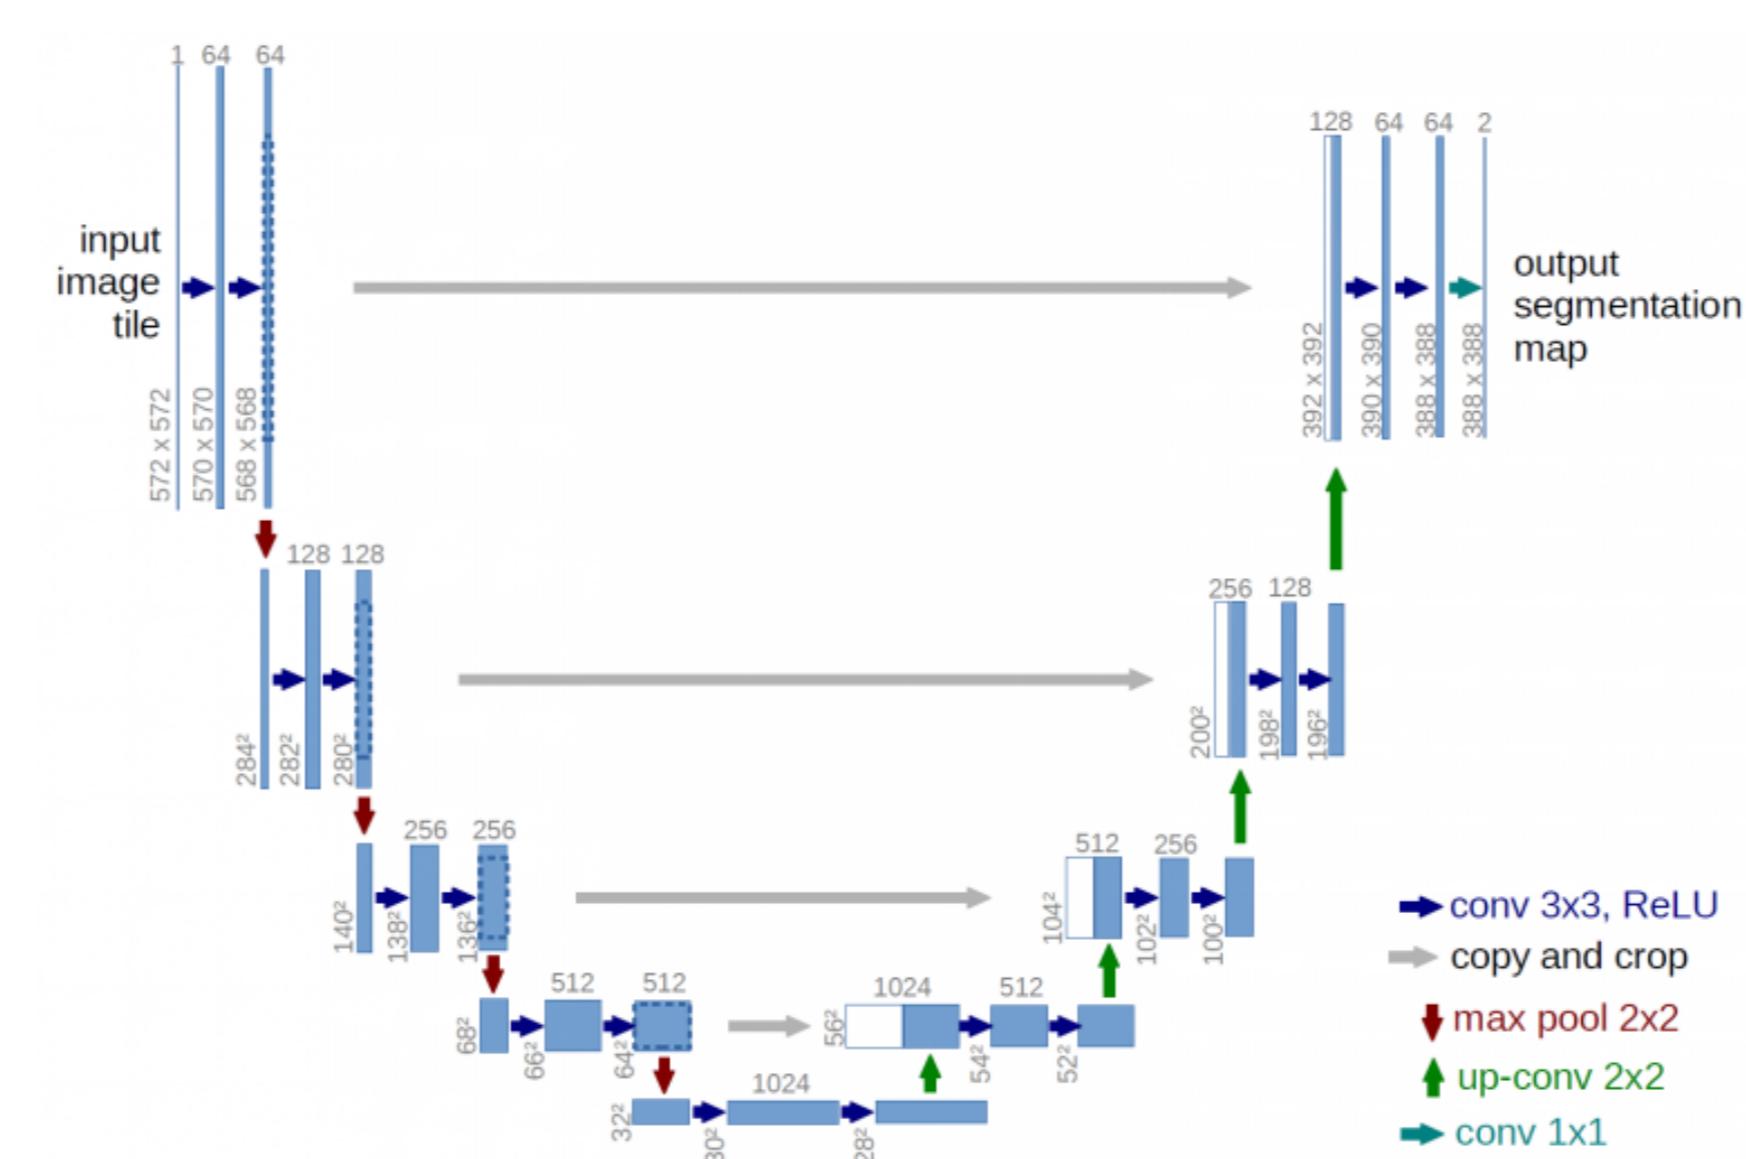


Figure 5: Arquitetura de uma U-Net.

A forma de treinamento escolhida é dividida em três partes:

- Treinar a rede com uma resolução 4 vezes menor;
- Treinar a rede com uma resolução 2 vezes menor;
- Treinar a rede com a resolução original.

Esse treinamento permite alcançar bons resultados com menos tempo de processamento. A métrica utilizada no treinamento é conhecida como IoU (*Intersection over union*).

## 3. Resultados e Discussão

O algoritmo de visão computacional clássica se mostrou suficiente para o processo de segmentação, contudo, apresenta limitações. Uma das resultados obtidos pelo algoritmo clássico é a própria Figura 2. Apesar o ótimo resultado, o algoritmo é altamente dependente da cor da madeira, necessitando que em condições de luminosidade adversas ajustes finos precisem ser feitos manualmente. Essa solução em específico também não é capaz realizar a segmentação para tipos de madeira muito diferentes. A CNN, por outro lado, obteve resultados semelhantes. O resultado da inferência da CNN quando a entrada é a Figura 1 por ser visto na Figura 6. Esse resultado pode ser facilmente melhorado aplicando o mesmo processamento feito no algoritmo clássico.

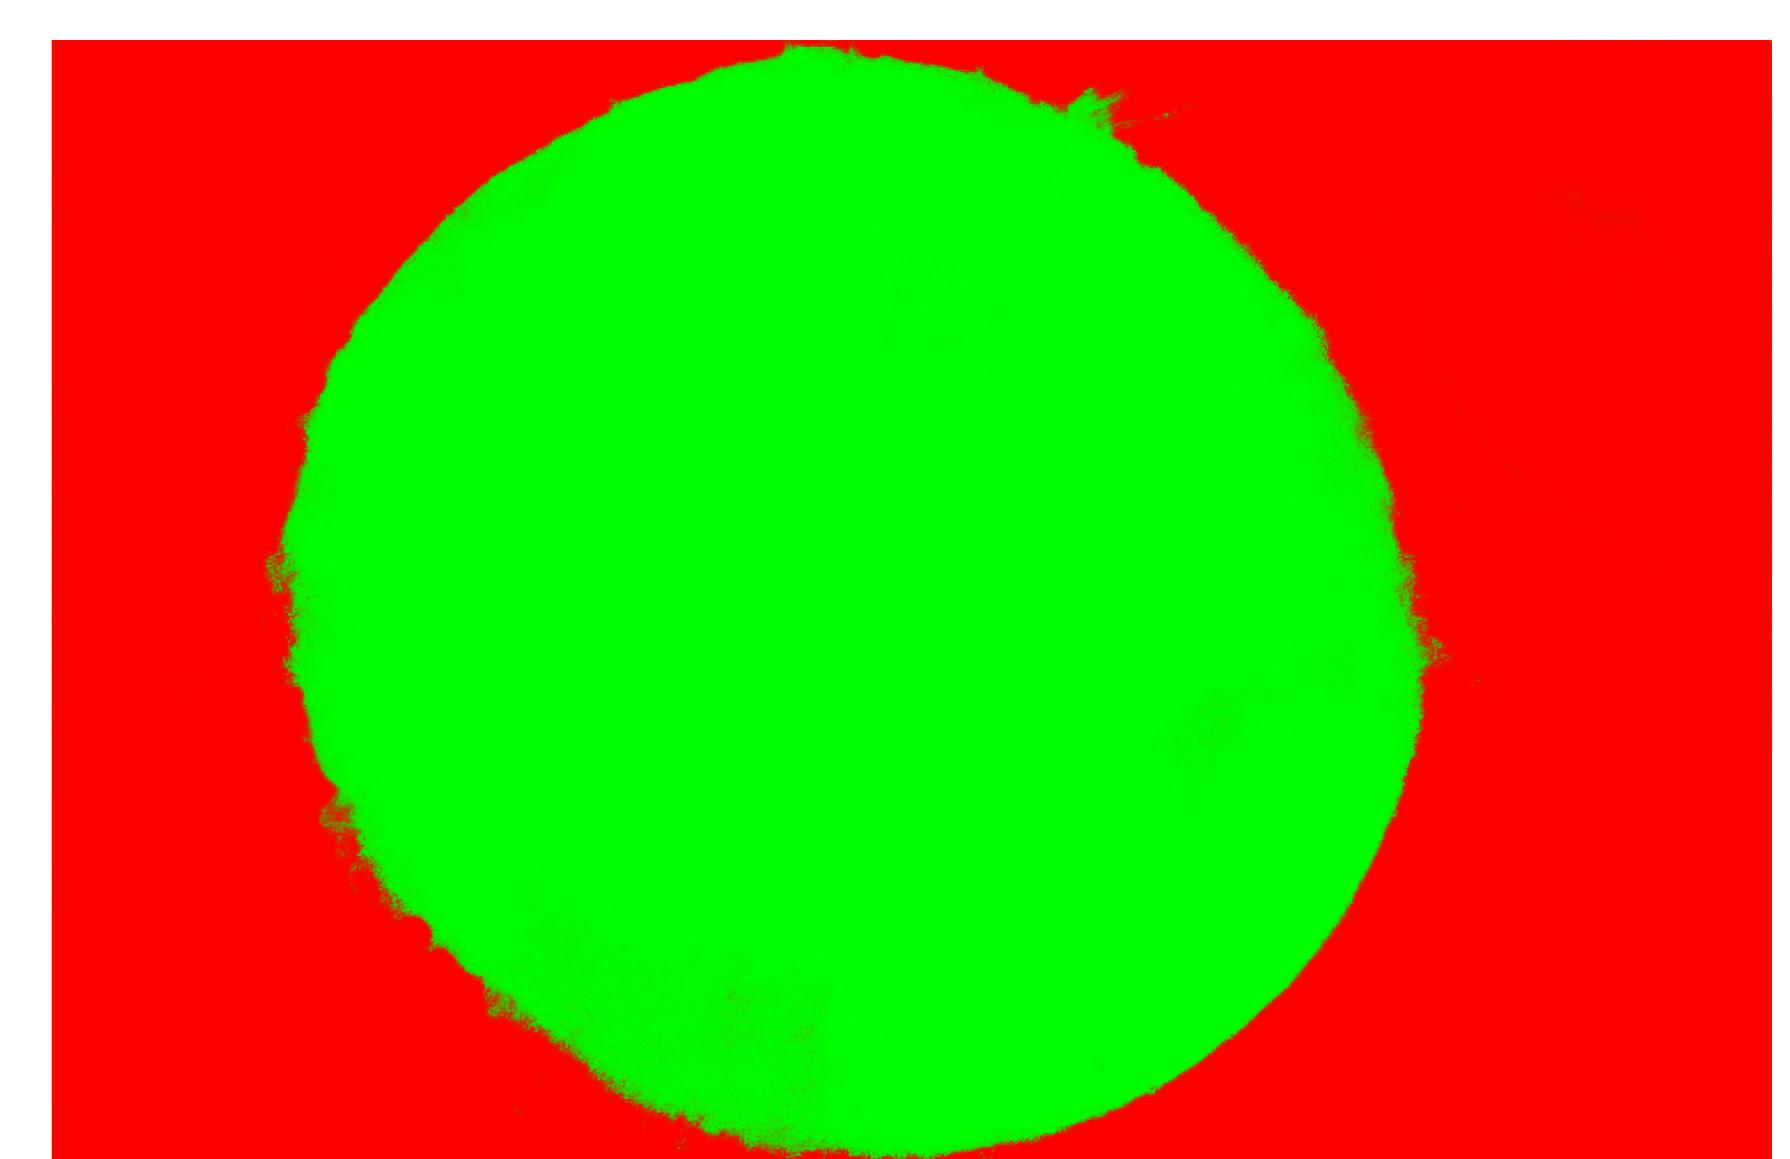


Figure 6: Resultado da CNN.

É importante ressaltar que os resultados da CNN foram obtidos com poucas épocas de treinamento. Para o último treinamento, realizado com a resolução original das imagens, obtiveram-se as seguintes métricas:

Table 1: Métricas de treinamento da CNN.

epoch	train loss	IoU metric	time
0	0.169930	0.988759	1:39
1	0.141255	0.992406	1:37
...	...	...	...
8	0.042674	0.983961	1:37
9	0.036680	0.984380	1:37

O conjunto de treinamento utilizado é composto por 30 imagens distintas, sem o uso de *data augmentation*. O treinamento de mostrou rápido e apresentou boa métrica IoU.

## 4. Conclusão

Em geral ambas as abordagens apresentaram bons resultados. Contudo, a CNN se mostrou mais robusta para trabalhar com condições adversas e com madeiras de diferentes tipos. Essa robustez surge justamente porque o banco de imagens utilizado possui diversos exemplos de madeiras. Dentro do mesmo banco de imagens o algoritmo clássico não foi capaz de segmentar corretamente os diversos exemplos, necessitando de ajustes finos para cada espécie de madeira.

Os resultados apontam que o algoritmo clássico tem dificuldades em segmentar diferentes espécies de madeira sem ajustes finos, já a CNN é capaz de segmentar facilmente dentre as espécies, porém, deixa alguns ruídos na imagem. A solução ideal então é realizar a segmentação através da CNN e, dada essa saída, aplicar as operações clássicas de morfologia e envoltório convexo para obter o resultado final.